

手写英文字母识别系统——中期进展报告

项目名称：手写英文字母识别系统

团队成员：恽律、倪豪杰、王天佐、侯冠宇

提交日期：2026年5月

一、项目概述

本项目的目标是设计并实现一个基于深度学习的手写英文字母识别系统。系统采用 EMNIST Letters 数据集（26 个字母类别，约10万张样本），计划探索并使用卷积神经网络（CNN）进行图像分类，并与传统机器学习方法进行性能对比，最终交付一个可交互的识别应用。**截至中期阶段，本项目已圆满完成数据采集、数据清洗、预处理以及全面的数据分析与可视化工作**，为下一阶段的模型构建打下了坚实的数据基础。

二、数据处理与分析细节（已完成）

本阶段的核心任务是建立高质量的数据流水线，具体实施细节如下：

2.1 数据来源与自动化采集

- 数据集**：EMNIST Letters（来源：Kaggle, crawford/emnist）
- 数据规模**：训练集 emnist-letters-train.csv（约200 MB，88,800张图），测试集 emnist-letters-test.csv（约30 MB，14,800张图）。
- 采集方式**：编写了自动化的 data_process.py 脚本，集成 Kaggle API 实现一键下载、解压与校验，确保了数据获取的工程化和可复现性。

2.2 数据清洗与预处理核心工艺

针对 EMNIST 原始数据的特殊情况，我们实施了严格的预处理：

- 缺失与去重**：使用 pandas 剔除空值和重复数据。
- 图像纠偏**：EMNIST 原始图像存在逆时针90°旋转和镜像翻转的固有缺陷，我们通过 np.fliplr 结合 np.rot90(k=-1) 成功将其恢复至正常书写方向。
- 图像去噪**：引入 scipy.ndimage.median_filter 进行 3×3 中值滤波，有效消除了手写笔画边缘的孤立噪点而不破坏字迹本身。
- 标准化**：将像素值统一归一化至 [0, 1] 区间（float32格式），标签处理为 0-25，完美对齐深度学习框架的输入规范。
- 持久化存储**：处理完毕的数据转存为 .npy 二进制格式，使后续读取速度相比 CSV 提升10倍以上。

2.3 数据分析与可视化（EDA）

为了验证清洗效果并探索数据特征，我们编写了可视化分析模块，生成了以下5类关键图表（均已导出为高清图）：

- 类别分布直方图**：验证了26个字母样本量分布完全均衡，排除了模型训练可能遇到的类别不平衡隐患。

- 2. 随机样本展示网格：**直观检验了图像纠偏与去噪工艺的实际效果，字迹清晰端正。
- 3. 整体平均图像热力图：**展示了像素分布的整体聚焦点，无异常偏移。
- 4. 单类字母平均图像：**提取了A-Z每个字母的“标准书写形态”，确认了标签与图像的映射完全正确。
- 5. PCA降维散点图：**对高维图像像素进行主成分分析（PCA）降维至二维。结果显示，前两个主成解释方差合计仅约 13%（线性可分性差），这从数据科学的角度充分论证了后续引入 CNN 等非线性深度学习模型的必要性。

三、遇到的问题及解决方案

在前期数据处理阶段，我们遇到了以下技术挑战并已成功解决：

遇到的问题

解决方案

1. Kaggle API 认证失败

运行采集脚本时提示 `ValueError: Missing username`，无法拉取数据。

查阅官方文档，生成 `kaggle.json` 令牌并正确配置到用户目录的 `.kaggle` 文件夹下，完善了自动化下载脚本的环境依赖。

2. 脚本路径拼接错误

可视化脚本运行时抛出 `FileNotFoundError`，系统尝试读取 `data/data/processed/` 导致报错。

重构了路径配置逻辑，采用 `os.path.dirname(os.path.abspath(file))` 动态获取绝对路径，彻底消除了不同执行环境下的路径依赖错误。

3. 绘图中文乱码

生成数据分析图表时，标题和坐标轴的中文字符显示为方块。

在可视化脚本顶部全局配置了 `matplotlib` 的 `font.sans-serif` 参数（指定为 `SimHei/黑体`），并设置 `axes.unicode_minus=False`。

四、当前整体进展与下一步计划

当前进展总结（100%完成）

自动化数据采集流水线

图像定向纠偏、去噪与标准化清洗

EMNIST 数据集探索性分析（EDA）与高质量图表生成

下一步计划（即将启动）

- 模型构建与训练：**基于本阶段生成的 `.npy` 高质量数据，开始构建 CNN 深度学习网络，并搭建传统机器学习（如随机森林、SVM）作为基线模型进行性能打擂。
- 系统应用开发：**使用前端轻量化框架封装训练好的最佳模型，实现支持用户手写输入的交互界面。
- 撰写最终报告：**整合数据分析图表、模型性能指标（F1-score、混淆矩阵等）准备结题汇报。